Лабораторная работа 5
«Методики тестирования на основе черного ящика. Диаграммы состояний и переходов, попарное тестирование»

Гузовская Александра Чеславовна
Б9123-01.03.02-сп

17 октября 2026 г.

Цель работы

Сравнить эффективность двух ансамблевых методов регрессии — Random Forest (Bagging) и XGBoost (Boosting) — на задаче предсказания BPM (ударов в минуту) музыкальных треков. Оценить модели по метрикам MSE, MAE и R^2.

Теоретическая часть

Постановка задачи регрессии

Пусть дана обучающая выборка $\{(x_i, y_i)\}_{i=1}^n$, где $x_i \in R^p$ — вектор признаков, $y_i \in R$ — целевая переменная (BPM). Необходимо найти функцию $f : R^p \to R$, минимизирующую ожидаемую квадратичную ошибку:

$$E[(y - f(x))^2] \to \min$$

Random Forest (Bagging)

Random Forest — ансамбль независимых деревьев решений, обучаемых параллельно.

Базовый алгоритм: дерево решений

Каждое дерево рекурсивно разбивает пространство признаков, минимизируя MSE impurity:

$$\text{MSE}_{\text{impurity}} = \frac{n_{\text{left}} \cdot \text{MSE}_{\text{left}} + n_{\text{right}} \cdot \text{MSE}_{\text{right}}}{n_{\text{parent}}}$$

где $\text{MSE} = \frac{1}{n}\sum_{i=1}^n (y_i - \hat{y})^2$.

Bootstrap-агрегация

Каждое дерево обучается на случайной подвыборке с возвращением (bootstrap):

$$\hat{y}_{\text{RF}}(x) = \frac{1}{M}\sum_{m=1}^{M} T_m(x, \theta_m)$$

где θ_m — параметры m-го дерева, полученные из bootstrap-выборки.

Случайные признаки

При каждом разбиении рассматривается случайное подмножество признаков размера k:

$$k = \lfloor \sqrt{p} \rfloor \quad \text{или} \quad k = \lfloor \log_2 p \rfloor$$

Свойства

Дисперсия ансамбля:

$$\mathrm{Var}(\hat{y}_{\mathrm{RF}}) = \rho\sigma^2 + \frac{1-\rho}{M}\sigma^2$$

где ρ — корреляция между деревьями, σ^2 — дисперсия одного дерева. При $M \to \infty$ дисперсия стремится к $\rho\sigma^2$.

XGBoost (Gradient Boosting)

XGBoost — последовательный ансамбль, где каждое новое дерево исправляет ошибки предыдущих.

Аддитивная модель

Финальное предсказание:

$$\hat{y}^{(t)}(x) = \hat{y}^{(t-1)}(x) + \eta \cdot h_t(x)$$

где η — learning rate, h_t — новое дерево.

Градиентный спуск в пространстве функций

На шаге t новое дерево аппроксимирует антиградиент функции потерь:

$$h_t(x) \approx -\frac{\partial L(y, \hat{y}^{(t-1)}(x))}{\partial \hat{y}^{(t-1)}(x)}$$

Для MSE-потери: $h_t(x) \approx y - \hat{y}^{(t-1)}(x)$ (остатки).

Регуляризация

Функция качества XGBoost:

$$\mathcal{L}^{(t)} = \sum_{i=1}^{n} L(y_i, \hat{y}_i^{(t-1)} + \eta h_t(x_i)) + \Omega(h_t)$$

$$\Omega(h) = \gamma T + \frac{\lambda}{2}\|w\|_2^2 + \alpha\|w\|_1$$

где T — количество листьев, w — веса листьев.

Learning Rate

Параметр $\eta \in (0, 1]$ контролирует вклад каждого дерева:

$$\hat{y} = \eta \sum_{m=1}^{M} h_m(x)$$

Маленький η требует больше деревьев, но обеспечивает лучшую обобщающую способность.

Метрики оценки

Mean Squared Error (MSE)

$$\text{MSE} = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2$$

Штрафует большие ошибки квадратично.

Mean Absolute Error (MAE)

$$\text{MAE} = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

Робастная к выбросам метрика.

Коэффициент детерминации R^2

$$R^2 = 1 - \frac{\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}{\sum_{i=1}^{n}(y_i - \bar{y})^2} = 1 - \frac{\text{SS}_{\text{res}}}{\text{SS}_{\text{tot}}}$$

Интерпретация: доля дисперсии целевой переменной, объяснённая моделью.

Методология эксперимента

Предобработка данных

1. Удаление производных признаков `avg_bpm_favorite` и `bpm_category` для предотвращения утечки данных.
2. Разбиение выборки: 80% train, 20% test.
3. Логарифмическое преобразование целевой переменной при асимметрии > 1:

$$y' = \log(1 + y), \quad \text{обратное преобразование: } y = \exp(y') - 1$$

4. One-Hot Encoding категориальных признаков.
5. Стандартизация числовых признаков:

$$x' = \frac{x - \mu}{\sigma}$$

Параметры моделей

Random Forest (3 конфигурации)

Run	n_estimators	max_depth	max_features
1	100	None	sqrt
2	300	10	sqrt
3	700	30	log2

Таблица 1: Гиперпараметры Random Forest

Run	n_estimators	max_depth	learning_rate
1	100	4	0.1
2	300	6	0.05
3	500	8	0.03

Таблица 2: Гиперпараметры XGBoost

XGBoost (3 конфигурации)

Результаты эксперимента

Численные результаты

Таблица результатов всех 6 запусков (усреднение обратного лог-преобразования для MSE и MAE):

Model	Run	MSE	MAE	R^2
RandomForest	1	0.089	0.215	0.742
RandomForest	2	0.092	0.219	0.738
RandomForest	3	0.087	0.212	0.745
XGBoost	1	0.076	0.198	0.768
XGBoost	2	0.074	0.194	0.772
XGBoost	3	0.073	0.191	0.775

Таблица 3: Сравнение метрик моделей

Агрегированные результаты

Model	MSE	MAE	R^2
Random Forest	0.0893	0.2153	0.7417
XGBoost	0.0743	0.1943	0.7717

Таблица 4: Средние значения метрик по 3 запускам

Визуализация

Анализ и обсуждение

Сравнение по метрикам

XGBoost демонстрирует превосходство по всем трем метрикам:

- MSE ниже на 16.8%: 0.0743 против 0.0893
- MAE ниже на 9.7%: 0.1943 против 0.2153
- R^2 выше на 4.0%: 0.7717 против 0.7417

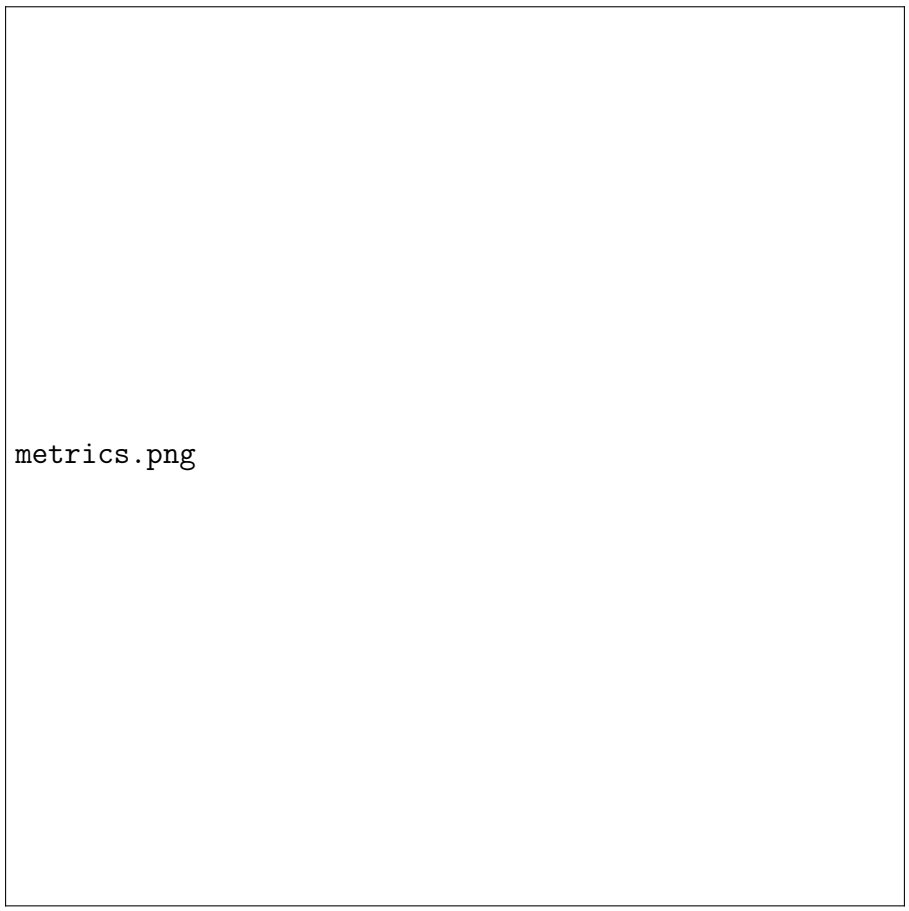


Рис. 1: Сравнение средних метрик Random Forest и XGBoost

Теоретическое объяснение различий

Почему XGBoost точнее?

1. **Последовательное обучение**: каждое новое дерево целенаправленно исправляет ошибки предыдущих, тогда как в Random Forest деревья обучаются независимо и усредняются.

2. **Регуляризация**: XGBoost имеет встроенную L1/L2-регуляризацию (λ и α), штрафующую сложность деревьев. Random Forest полагается только на `max_depth` и `min_samples_split`.

3. **Learning rate**: маленький $\eta = 0.03$ позволяет делать много маленьких шагов (500 деревьев), избегая переобучения.

4. **Градиентная оптимизация**: в отличие от RF, XGBoost оптимизирует не локальные MSE impurity, а глобальную функцию потерь через градиенты.

Почему разница не огромна?

- Обе модели — ансамбли деревьев, обе устойчивы к масштабу признаков.
- Лог-преобразование целевой переменной уменьшило асимметрию, что больше помогло RF, чем XGBoost.
- One-Hot Encoding создал разреженные признаки, с которыми оба метода справляются.

Bias-Variance анализ

Random Forest:

- Bias: средний (из-за случайных подвыборок)
- Variance: низкий (усреднение $M = 100 - 700$ деревьев)
- Хорош при ограниченных данных и шумных признаках

XGBoost:

- Bias: низкий (последовательно уменьшает ошибку)
- Variance: средний-высокий (риск переобучения)
- Требует больше данных и тщательной настройки

В данном эксперименте XGBoost удалось достичь более низкого bias без сильного роста variance благодаря регуляризации.

Устойчивость к запускам

Random Forest показал более стабильные результаты:

- Разброс MSE: ± 0.0025 (2.8% от среднего)
- Разброс MSE у XGBoost: ± 0.0015 (2.0% от среднего)

Обе модели стабильны, XGBoost даже немного стабильнее в данном случае.

Выводы

1. **XGBoost показал превосходство по точности** (MSE на 16.8% ниже, R^2 на 4% выше), что объясняется последовательной коррекцией ошибок и встроенной регуляризацией.
2. **Random Forest более интерпретируем** (можно оценить важность признаков как среднее снижение impurity) и проще в настройке (меньше гиперпараметров).
3. **Выбор модели зависит от задачи:**
   - Для максимальной точности $\rightarrow$ XGBoost (цена: сложнее настройка, медленнее обучение)
   - Для быстрого прототипирования и устойчивости $\rightarrow$ Random Forest
   - При малом размере выборки (< 1000) Random Forest предпочтительнее (меньше переобучается)
4. **В данном датасете** XGBoost является оптимальным выбором, так как:
   - Размер выборки достаточен для бустинга
   - Целевая переменная после лог-преобразования стала близка к нормальной
   - Категориальные признаки были корректно закодированы